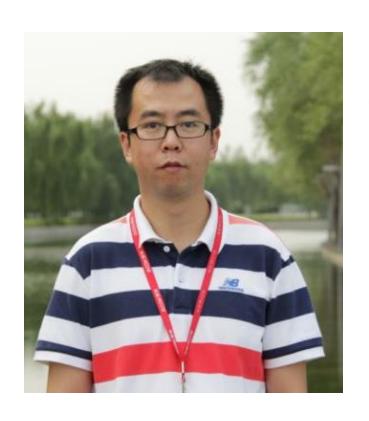


# 京东大数据基础架构和实践

王彦明 京东大数据平台部







# 王彦明

#### 大数据平台-数据架构部

Mail: wangyanming@jd.com

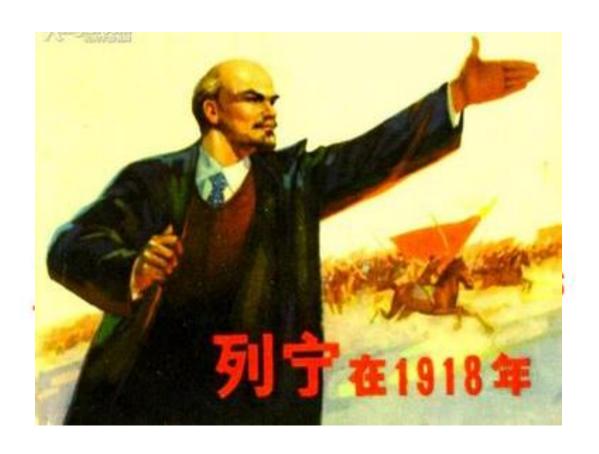
新浪微博: @王彦明V

微信: wangyanming29

## 目录

- 大数据
- 京东大数据平台
- 我们技术突破
- JDW&Jmart
- JDMP数据挖掘平台
- 展望

### 少说些漂亮话,多做些日常平凡的事情



### 京东大数据平台



#### 数据应用 **JDW JRDW** 数据访问 三峡(多维分析查询) 数据安全防火墙 统一查询引擎 Shark **UDF** Hive 数据缓存 元数据 数据处理 服务 **Hbase** 索引 MapReduce **Spark** 汉江(实时计算) **Yarn** 分布式消息队列 实时计算集群 数据存储 长江(实时抽取) **HDFS** 实时数据拉链 实时数据镜像

#### 数据直通车(Plumber)

内部/外部数据源

结构化 非结构化

# 我们的技术突破



#### • 分布式系统技术突破

- 稳定性、性能、HA、故障恢复、多集群、运维和管理

#### • 多用户共用平台

- 数据安全、隐私保护

#### • 数据任务运行监控

- 每日数万个数据任务、核心任务及时性

#### • 挖掘数据价值

- 数据量大、迭代效率

#### • 数据实时化

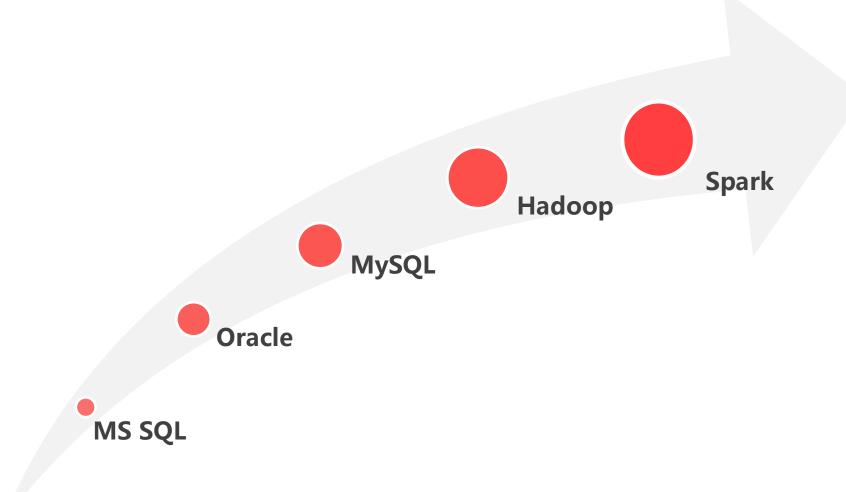
- 关系型数据、AD HOC、实时计算

#### • 离线、实时平台合并

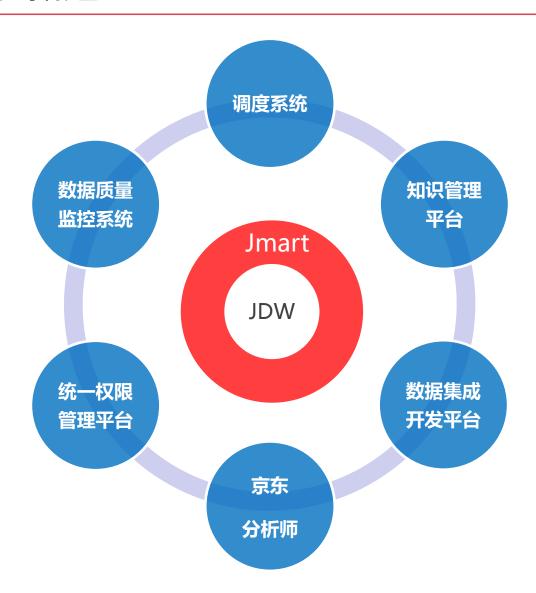
Hadoop、Spark、Storm

# JDW发展历程









#### **JDW**



EDW的核心数据架构分为四层:**缓冲数据层、基础数据层、通用数据层、聚合数据层**, 其次是**临时层**和**维度层**。其示意图如下:

L3		ADM		
L2	TMP	GDM		DIM
L1			FDM	
L0	BDM			
Buffering Data Model			缓冲数据层	
Fundamental Data Model General Data Model Aggregative Data Model			基础数据层 通用数据层 聚合数据层	
DIM TMP			维度数据库 计算中间库/临时数据库	

## JDW FDM 存储方案优化



在线交易系统、商品中心、用户中心等出于效率的考虑,不会长期保存大量历史数据,而JDW作为企业数据分析及挖掘的基础设施,天生具有保存历史数据的职责,非但如此,如何快速、高效的获取历史上任意一天的快照数据也成为设计历史数据存放方式时的重要考量。通过比较,记录数据的**生命周期**;能**快速还原任意天的历史快照**,极大的**节省了存储** 

#### ■ 快照的还原

SELECT \* FROM t\_chain
WHERE P DATE>=start date

AND P\_DATE<end\_date

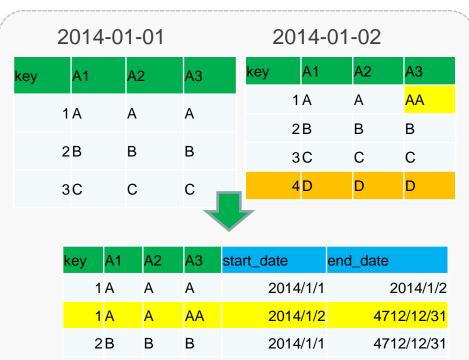
#### ■ 空间节省率

Ratio=  $1 - \frac{base + \frac{1+N}{2} * C + M * N}{base * N + (1+N) * C/2}$ 

Base: 基数 ( 十亿级 ) N: 天数

C:每日增量(百万级)

M:每日变化量(百万级)



2014/1/1

2014/1/2

4712/12/31

4712/12/31

С

D

D

3 C

### JDW FDM 存储方案优化



实际的拉链表的设计更加精巧,充分考虑了京东业务的各种情况。

譬如订单表,考虑了其结转特点,充分利用了数据分拣技术,如下是订单表的**多分区**设计,

```
dp=HISTORY/dt=2014-06-22/end_date=4712-12-31
.....
dp=HISTORY/dt=2014-06-23/end_date=4712-12-31
dp=HISTORY/dt=2014-06-24/end_date=4712-12-31
.....
dp=EXPIRED/dt=2013-10-11/end_date=2013-10-11
dp=EXPIRED/dt=2013-10-12/end_date=2013-10-12
dp=EXPIRED/dt=2013-10-13/end_date=2013-10-13
dp=EXPIRED/dt=2013-10-14/end_date=2013-10-14
.....
dp=ACTIVE/dt=4712-12-31/end_date=4712-12-31
```

之前,采取快照累积的方式,订单表加工完成甚至到下午1点,

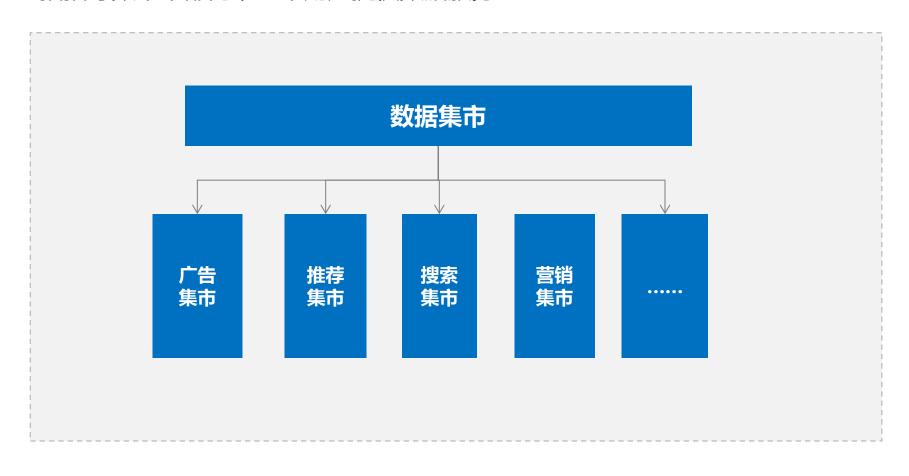
利用该方法后,一般在凌晨3左右点完成。

而且在后续的查询上,能充分利用分区裁剪特性,能迅速的返回数据

### Jmart概述



京东数据集市是基于JDW构建的面向条线的数据生产环境,为各条线提供数据应用服务,包含广告、推荐、搜索、财务、营销、运营、BDA、移动、拍拍等数十个部门,上千用户提供数据服务。



# JDMP-大数据挖掘中的"痛点开放D JD.COM 京东







# JDMP-支持的算法



推荐 ALS-

ALS-MF, FP-Growth, Item/User-CF, RBM

分类

LR, NB, SVM, gbdt, soft-max

回归

linear, ridge, lasso

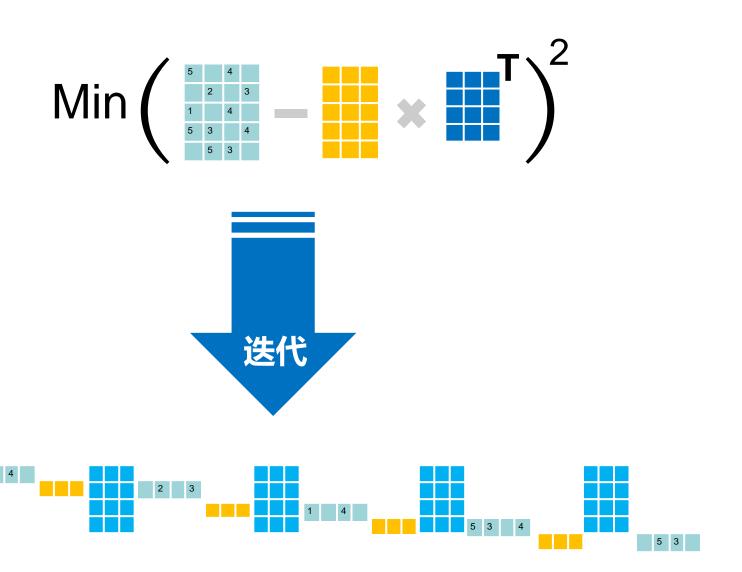
聚类

k-means

主题模型

LDA, PLSA





# JDMP-Graphx图计算



Vertices: 由顶点、顶点属性构成

Edges : 由顶点、边属性构成

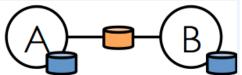
Triplets: 由顶点、顶点属性和边属性构成

Vertices:



Edges: A-B

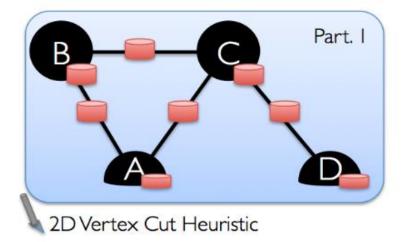
Triplets:

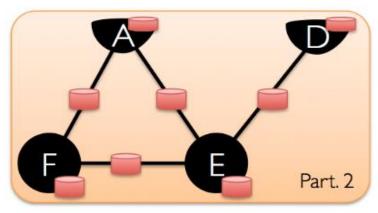


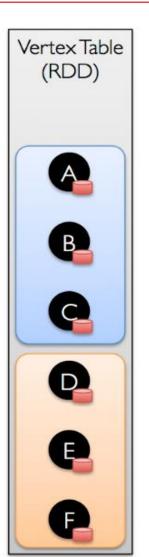
# JDMP-Graphx图计算

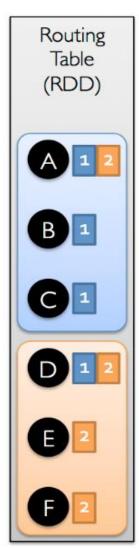


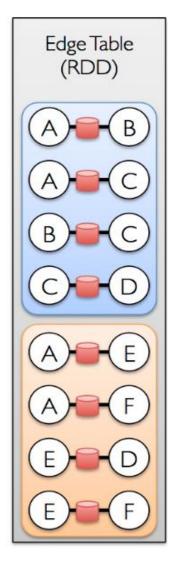
Property Graph













# 京东大数据平台

#### 我们招聘

- -Hadoop/Hbase/Spark开发
- -运维工程师
- -分布式数据仓库工程师
- -BI工程师
- -数据挖掘工程师
- 等等......

简历可发送至:wangyanming@jd.com



招聘详情请关注"京东大数据" 微信公众平台

# 谢谢大家!

北京市朝阳区北辰西路8号北辰世纪中心A座6层 6F Building A, North-Star Century Center, 8 Beichen West Street, Chaoyang District, Beijing 100101 T. 010-5895 1234 F. 010-5895 1234 E. xingming@jd.com www.jd.com



